

大语言模型在教育领域的应用研究

系统性文献综述、元分析、参考文献与附录

版本：4.0

生成日期：2026年9月10日

内容与附录

一、研究背景

近年来，大语言模型（Large Language Models, LLMs）在自然语言处理领域取得显著进展。随着 Transformer 架构的提出与迭代，基于海量语料预训练的模型在文本生成、语义理解、知识问答等任务上展现出较强能力。教育领域作为知识密集型场景，成为 LLMs 应用研究的重要方向之一。

本研究综述聚焦 2020 年至 2025 年间的相关文献，梳理 LLMs 在教学设计、学习支持、教育评估三个方面的应用现状与挑战。研究采用系统性文献综述与元分析相结合的方法，旨在量化 LLMs 对学习成效的平均影响，并识别调节变量。

LLMs 在教育中的应用呈现“技术推动—场景适配—效果检验—伦理反思”四阶段循环特征。早期研究多聚焦技术可行性验证，中期转向具体教学场景适配，近期则更多关注学习成效的实证检验与伦理风险治理。

二、核心概念界定

大语言模型（LLM）：基于大规模文本语料预训练、具备通用语言生成与理解能力的神经网络模型。

自适应学习（Adaptive Learning）：根据学习者知识水平与行为数据动态调整学习内容与路径的教学方法。

形成性评价（Formative Assessment）：在教学过程中持续进行、用于改进教与学的评价方式。

智能辅导系统（Intelligent Tutoring System, ITS）：利用人工智能技术模拟一对一辅导的教学系统。

提示工程（Prompt Engineering）：通过设计输入提示来引导大语言模型产生目标输出的方法。

检索增强生成（Retrieval-Augmented Generation, RAG）：在生成答案前先从外部知识库检索相关文本，以缓解模型幻觉的技术范式。

认知负荷理论（Cognitive Load Theory）：认为工作记忆容量有限，教学设计应避免超出学习者认知负荷的理论框架。

人机协同（Human-AI Collaboration）：强调人类与人工智能各自发挥优势、共同完成任务的协作模式。

效应量（Effect Size）：衡量干预效果大小的统计指标，本研究采用 Hedges' g。

异质性（Heterogeneity）：元分析中研究间效应量差异的程度，常用 I^2 统计量衡量。

易混淆提示：自适应学习强调“路径动态调整”，智能辅导系统强调“模拟一对一辅导”，二者常被混用，但前者更关注学习路径，后者更关注交互形态。

三、理论框架

本研究基于认知负荷理论与人机协同理论构建分析框架。认知负荷理论认为，工作记忆容量有限，教学设计应避免超出学习者认知负荷。人机协同理论则强调人类与人工智能各自发挥优势、共同完成任务。

设学习者 i 在学习任务 j 上的学习成效为 Y_{ij} ，可表示为：

$$Y_{ij} = \beta_0 + \beta_1 \cdot LLM_{ij} + \beta_2 \cdot PriorKnowledge_{ij} + \beta_3 \cdot (LLM_{ij} \times PriorKnowledge_{ij}) + u_i + \varepsilon_{ij}$$

其中：

LLM_{ij} 表示是否使用 LLMs 辅助 (0/1) ；

PriorKnowledge_{ij} 表示先前知识水平 (标准化分数) ；

$\beta \square$ 为交互项系数，用于检验 LLMs 对不同基础学习者的差异化影响；

u_i 为学习者随机效应， ϵ_{ij} 为残差项。

元分析中，综合效应量计算公式为：

$$g\square = \sum (w_i \cdot g_i) / \sum (w_i)$$

其中 $w_i = 1 / (v_i + \tau\square)$ ， v_i 为研究内方差， $\tau\square$ 为研究间方差。

异质性检验采用 Q 统计量与 $I\square$ 统计量：

$$I\square = [(Q - df) / Q] \times 100\%$$

四、研究方法

本研究采用系统性文献综述与元分析相结合的方法，检索数据库包括 Web of Science、Scopus 与中国知网。检索关键词包括 “large language model” “education” “adaptive learning” “intelligent tutoring” 等。初检获得文献 1247 篇，经标题与摘要筛选后保留 186 篇，最终纳入 62 篇进行全文分析，其中 28 篇提供足够数据进入元分析。

纳入标准包括：（1）发表于 2020 年至 2025 年；（2）以 LLMs 为核心技术；（3）包含实证数据或系统设计。排除标准包括：（1）纯理论思辨文章；（2）非教育场景应用；（3）重复发表文献。

质量评估采用混合方法评估工具（MMAT），62 篇文献中高质量 18 篇，中等质量 31 篇，低质量 13 篇。

五、研究结果

5.1 文献特征分布

特征	类别	篇数	占比
学段	高等教育	36	58.1%
学段	语言学习	14	22.6%
学段	基础教育	7	11.3%
学段	职业教育	5	8.1%
研究设计	随机对照实验	21	33.9%
研究设计	准实验	24	38.7%
研究设计	案例研究	17	27.4%
研究时长	少于 1 个月	29	46.8%
研究时长	1 - 6 个月	24	38.7%
研究时长	超过一学期	9	14.5%

5.2 元分析结果

结果变量	研究数	Hedges' g	95% CI	I ²
事实性知识	18	0.42	[0.31, 0.53]	46%
开放性推理	12	0.11	[-0.04, 0.26]	68%
学习动机	9	0.35	[0.19, 0.51]	52%
自我效能感	7	0.28	[0.10, 0.46]	61%

5.3 调节效应分析

调节变量	类别	Hedges' g	95% CI	Q_between	p
学段	高等教育	0.38	[0.26, 0.50]	6.42	.04
学段	基础教育	0.21	[0.03, 0.39]		
研究时长	少于 1 个月	0.47	[0.33, 0.61]	8.17	.02
研究时长	超过一学期	0.19	[0.01, 0.37]		
反馈类型	即时反馈	0.44	[0.30, 0.58]	5.91	.05
反馈类型	延迟反馈	0.23	[0.06, 0.40]		

5.4 关键实验数据

一项针对 320 名中学教师的调查显示，使用 LLMs 辅助备课后，平均备课时间从每周 8.5 小时下降至 6.2 小时，但约 41% 的教师报告曾发现模型生成内容存在事实性错误。

一项随机对照实验将 180 名大学生分为实验组与对照组，实验组使用 LLMs 辅助学习，对照组使用传统教材。结果显示，实验组在事实性知识测试中平均分高出 12.4%，但在开放性推理任务中仅高出 3.1%，差异不显著（ $p = .18$ ）。

自动评分研究中，LLMs 在开放题评分上与人工评分具有中等程度一致性（Cohen's $\kappa = 0.54$ ），但在创造性任务上一致性较低（Cohen's $\kappa = 0.21$ ）。

数据冲突提示：5.2 表格显示事实性知识效应量 $g = 0.42$ ，但附录 A 中一项 2025 年最新研究报告的效应量为 $g = 0.29$ 。两者差异可能源于样本差异或发表偏倚，读者需谨慎解读。

六、图表描述

图 1：LLMs 教育应用研究数量年度趋势（2020 - 2025）

图 1 为折线图，横轴为年份（2020 - 2025），纵轴为发表文献数量。2020 年仅 3 篇，2021 年 7 篇，2022 年 12 篇，2023 年 21 篇，2024 年 34 篇，2025 年 45 篇。整体呈指数增长趋势，2023 年后增速明显加快，与 ChatGPT 发布引发的研究热潮吻合。

图 2：不同学段效应量森林图

图 2 为森林图，展示不同学段的效应量及置信区间。高等教育 $g = 0.38$, 95% CI [0.26, 0.50]; 语言学习 $g = 0.33$, 95% CI [0.18, 0.48]; 基础教育 $g = 0.21$, 95% CI [0.03, 0.39]; 职业教育 $g = 0.17$, 95% CI [-0.02, 0.36]。可见高等教育与语言学习效应量较高且显著，职业教育置信区间跨 0，不显著。

图 3：调节效应气泡图

图 3 为气泡图，横轴为研究时长（月），纵轴为效应量，气泡大小代表样本量。图中显示研究时长与效应量呈负相关趋势，即研究时长越长，效应量越小。

七、主要发现

应用分布不均：高等教育场景占比 58.1%，语言学习占比 22.6%，基础教育仅占 11.3%。

效果证据有限：62 篇文献中，仅 9 篇研究时长超过一学期；元分析显示事实性知识效应量 $g = 0.42$ ，开放性推理仅 $g = 0.11$ 且不显著。

教师角色变化：LLMs 更多扮演辅助工具角色，教师在教学设计与价值引导方面的作用不可替代。

伦理风险突出：学术诚信、数据隐私、算法偏见与过度依赖是主要伦理关切。

技术瓶颈明显：模型幻觉、领域知识更新滞后与多模态支持不足是当前主要技术限制。

调节效应显著：学段、研究时长与反馈类型均显著调节 LLMs 的学习成效，短期研究效应量普遍高于长期研究。

数据存在冲突：主元分析与附录 A 中最新研究在事实性知识效应量上存在差异（0.42 vs 0.29），提示结论需谨慎。

八、研究挑战

准确性挑战：LLMs 在专业学科知识上可能生成看似合理但实际错误的内容。

个性化挑战：如何基于学习者长期数据实现真正的自适应学习仍待探索。

评价挑战：如何评估 LLMs 对学习成效的长期影响缺乏统一标准。

伦理挑战：学生数据采集与使用边界尚不清晰。

公平性挑战：不同地区、不同语言背景的学习者获取 LLMs 资源的机会存在差异。

挑战间关联：准确性挑战与评价挑战相互影响——若模型输出不可靠，则难以评估其真实学习成效；伦理挑战与公平性挑战相互交织——数据采集越广泛，隐私与公平风险越突出。

九、未来展望

未来研究可在以下方向深入：一是构建学科领域的专用评测基准；二是探索人机协同的教学模式；三是加强多模态学习支持；四是建立教育场景下的伦理规范与数据治理框架；五是开展跨文化、跨学段的长期实证研究。

十、参考文献

[1] Vaswani, A., et al. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30, 5998 – 6008.

[2] Brown, T. B., et al. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33, 1877 – 1901.

[3] Kasneci, E., et al. (2023). ChatGPT for good? On opportunities and challenges of large language models for education. *Learning and Individual Differences*, 103, 102274.

[4] Zhai, X. (2022). ChatGPT user experience: Implications for education. *SSRN Electronic Journal*.

[5] 李政涛, 文娟. (2023). 大语言模型在教育中的应用与挑战. *教育研究*, 44(5), 32 – 45.

[6] 陈静, 王磊. (2024). 基于大语言模型的智能辅导系统设计与实证. *中国远程教育*, (3), 56 – 67.

[7] Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences* (2nd ed.). Lawrence Erlbaum Associates.

[8] Hedges, L. V., & Olkin, I. (1985). *Statistical Methods for Meta-Analysis*. Academic Press.

[9] García, M., & López, R. (2024). Large language models in Spanish higher education: A mixed-methods study. *Revista de Educación a Distancia*, 24(78), 1 – 22.

[10] Müller, S., & Schmidt, K. (2023). KI-gestütztes Lernen: Chancen und Risiken. *Zeitschrift für Pädagogik*, 69(4), 512 – 530.

[11] Tanaka, H., et al. (2025). The impact of LLM-based tutoring on Japanese EFL learners. *Language Learning & Technology*, 29(1), 45 – 68.

[12] Kim, J., & Park, S. (2024). AI tutoring in Korean secondary education: A randomized controlled trial. *Computers & Education*, 210, 104987.

十一、附录

附录 A：补充元分析数据（2025 年最新研究）

结果变量	研究数	Hedges' g	95% CI	I ²
事实性知识	6	0.29	[0.12, 0.46]	39%
开放性推理	4	0.08	[-0.11, 0.27]	55%

注：附录 A 数据来自 2025 年新增的 6 项研究，与主元分析（5.2 节）在事实性知识效应量上存在差异（0.29 vs 0.42），可能反映研究质量提升后效应量缩小的趋势。

附录 B：质量评估细则

采用 MMAT 工具，从定性、定量、混合方法三个维度评估。高质量标准包括：样本代表性、随机化、盲法、数据完整性、结果报告透明度。62 篇文献中，18 篇满足全部五项标准，31 篇满足三至四项，13 篇满足两项及以下。

附录 C：术语中英对照表

中文	英文
大语言模型	Large Language Model
自适应学习	Adaptive Learning
形成性评价	Formative Assessment
智能辅导系统	Intelligent Tutoring System
提示工程	Prompt Engineering
检索增强生成	Retrieval-Augmented Generation
认知负荷理论	Cognitive Load Theory
人机协同	Human-AI Collaboration
效应量	Effect Size
异质性	Heterogeneity