

大语言模型在教育领域的应用研究

测试问题集

版本：4.0

生成日期：2026年9月10日

共 26 道测试问题

十二、建议测试问题

基础题

问题一：这篇综述的研究主题是什么？

预期答案应包含：大语言模型在教育领域的应用研究，采用系统性文献综述与元分析相结合的方法。

问题二：文献综述检索了哪些数据库？

预期答案应包含：Web of Science、Scopus、中国知网。

问题三：初检获得多少篇文献？最终纳入多少篇？多少篇进入元分析？

预期答案应包含：初检 1247 篇，最终纳入 62 篇，其中 28 篇进入元分析。

进阶题

问题四：主要研究方向有哪三个？各自关注点是什么？

预期答案应包含：教学设计（教师端效率）、学习支持（学生端效果）、教育评估（评价端可靠性）。

问题五：LLMs 在教育应用中的主要伦理风险是什么？

预期答案应包含：学术诚信、数据隐私、算法偏见、过度依赖。

问题六：当前主要技术瓶颈有哪些？

预期答案应包含：模型幻觉、领域知识更新滞后、多模态支持不足。

表格检索题

问题七：元分析中，事实性知识与开放性推理的效应量分别是多少？是否显著？

预期答案应包含：事实性知识 $g = 0.42$, 95% CI [0.31, 0.53], 显著；开放性推理 $g = 0.11$, 95% CI [-0.04, 0.26], 不显著。

问题八：调节效应分析中，短期研究与长期研究的效应量差异如何？

预期答案应包含：少于 1 个月 $g = 0.47$, 超过一学期 $g = 0.19$, $Q_{\text{between}} = 8.17$, $p = .02$, 差异显著。

问题九：文献特征分布中，随机对照实验、准实验、案例研究各占多少篇？

预期答案应包含：随机对照实验 21 篇，准实验 24 篇，案例研究 17 篇。

图表理解题

问题十：图 1 显示的研究数量年度趋势是什么？

预期答案应包含：2020 年 3 篇，2021 年 7 篇，2022 年 12 篇，2023 年 21 篇，2024 年 34 篇，2025 年 45 篇，整体呈指数增长，2023 年后增速加快。

问题十一：图 2 中哪个学段的效应量不显著？为什么？

预期答案应包含：职业教育 $g = 0.17$, 95% CI [-0.02, 0.36], 置信区间跨 0, 因此不显著。

问题十二：图 3 显示了什么趋势？

预期答案应包含：研究时长与效应量呈负相关，研究时长越长，效应量越小。

公式理解题

问题十三：元分析中综合效应量的计算公式是什么？各符号含义是什么？

预期答案应包含： $g_{\square} = \sum (w_i \cdot g_i) / \sum (w_i)$, 其中 $w_i = 1 / (v_i + \tau_{\square})$, v_i 为研究内方差, $\tau_{\square}$ 为研究间方差。

问题十四：I² 统计量的计算公式是什么？如何解释 I² = 68%？

预期答案应包含：I² = [(Q - df) / Q] × 100%；I² = 68% 表示研究间异质性较高，约 68% 的总变异来自研究间差异而非抽样误差。

多跳推理题

问题十五：教师备课时间调查与随机对照实验分别得出了什么结论？二者共同说明了什么？

预期答案应包含：备课时间从每周 8.5 小时降至 6.2 小时，但 41% 教师发现事实性错误；实验组事实性知识高出 12.4%，开放性推理仅高出 3.1% 且不显著。共同说明 LLMs 在事实性、结构化任务上效果较好，在复杂推理与准确性上仍有局限。

问题十六：为什么说准确性挑战与评价挑战相互影响？

预期答案应包含：若模型输出不可靠，则难以评估其真实学习成效；评价标准缺失又会反过来掩盖准确性问题。

问题十七：结合元分析结果与调节效应分析，解释为什么短期研究效应量高于长期研究。

预期答案应包含：短期研究 $g = 0.47$ ，长期研究 $g = 0.19$ ；可能原因包括新鲜感效应、短期任务更偏事实性知识、长期学习涉及复杂推理与迁移，而 LLMs 在后者效果有限。

问题十八：62 篇文献的质量分布如何？这对综述结论的可靠性有何影响？

预期答案应包含：高质量 18 篇，中等质量 31 篇，低质量 13 篇；低质量文献占比较高，可能削弱结论可靠性。

冲突检测题

问题十九：主元分析与附录 A 在事实性知识效应量上是否存在冲突？如何解释？

预期答案应包含：存在冲突。主元分析 $g = 0.42$ ，附录 A 中 2025 年最新研究 $g = 0.29$ 。可能源于样本差异、研究质量提升或发表偏倚，提示结论需谨慎解读。

问题二十：图 2 中职业教育效应量与主元分析中开放性推理效应量有何相似之处？

预期答案应包含：两者置信区间均跨 0，均不显著；职业教育 $g = 0.17$ ，95% CI [-0.02, 0.36]；开放性推理 $g = 0.11$ ，95% CI [-0.04, 0.26]。

多语言文献题

问题二十一：参考文献中是否有非英语文献？请列举。

预期答案应包含：有。包括中文文献 [5] [6]、西班牙语文献 [9]、德语文献 [10]、日语作者文献 [11]、韩语作者文献 [12]。

问题二十二：Tanaka 等人（2025）研究的主题是什么？

预期答案应包含：基于 LLM 的辅导对日本 EFL 学习者的影响，发表于 Language Learning & Technology。

抗幻觉题

问题二十三：这篇综述是否提到了区块链在教育中的应用？

预期答案应包含：未提及。文档中未涉及区块链相关内容。

问题二十四：文档中是否给出了 LLMs 对学习成绩的长期追踪数据？

预期答案应包含：未给出。文档指出仅 9 篇研究时长超过一学期，缺乏长期追踪数据。

问题二十五：文档是否提到 LLMs 在医学教育中的具体应用？

预期答案应包含：未提及。文档未专门讨论医学教育场景。

问题二十六：文档是否提供了图 1 的原始数据表？

预期答案应包含：未提供原始数据表，仅在图 1 描述中给出各年度文献数量